Лабораторная работа 7

Петрушов Дмитрий, 1032212287

2024 г.

Российский университет дружбы народов, Москва, Россия

<u> </u>

Цель работы

Основной целью работы является изучение специализированных пакетов Julia для обработки данных.

Выполнение лабораторной работы

Считывание данных

```
[2]: # Считывание данных и их запись в структуру:
     P = CSV.File("programminglanguages.csv") |> DataFrame
    73×2 DataFrame
                                                                                     48 rows omitted
     Row year language
          Int64 String31
        1 1951 Regional Assembly Language
        2 1952 Autocode
        3 1954 IPL
        4 1955 FLOW-MATIC
        5 1957 FORTRAN
        6 1957 COMTRAN
        7 1958 LISP
        8 1958 ALGOL 58
        9 1959 FACT
```

```
# Функция определения по названию языка программирования года его создания:
function language created year(P,language::String)
loc = findfirst(P[:,2].==language)
return P[loc.1]
end
language created year (generic function with 1 method)
# Пример вызова функции и определение даты создания языка Python:
print(language created year(P, "Python"))
# Пример вызова функции и определение даты создания языка Julia:
language created vear(P."Julia")
1991
2012
```

Поиск "julia" со строчной буквы

```
# ФУНКЦИЯ ОПРЕДЕЛЕНИЯ ПО НАЗВАНИЮ ЯЗЫКА ПРОГРАММИРОВАНИЯ
# года его создания (без учёта регистра):
function language created year v2(P,language::String)
loc = findfirst(lowercase.(P[:,2]).==lowercase.(language))
return P[loc.1]
end
language created year v2 (generic function with 1 method)
# Пример вызова функции и определение даты создания языка iulia:
language created year v2(P, "julia")
2012
```

Построчное считывание данных

```
# Построчное считывание данных с указанием разделителя:
  Tx = readdlm("programminglanguages.csv", ',')
: 74×2 Matrix{Any}:
       "year" "language"
   1951
               "Regional Assembly Language"
               "Autocode"
   1952
   1954
               "IPL"
   1955
               "FLOW-MATTC"
   1957
               "FORTRAN"
   1957
               "COMTRAN"
   1958
               "LTSP"
   1958
               "ALGOL 58"
   1959
               "FACT"
   1959
               "COBOL"
   1959
               "RPG"
   1962
               "APL"
                                                                             6/31
```

```
: # Запись данных в CSV-файл:
CSV.write("programming_languages_data2.csv", P)
: "programming languages data2.csv"
```

Рис. 5: Запись данных в файл

```
# Инициализация словаря:
dict = Dict{Integer, Vector{String}}()

Dict{Integer, Vector{String}}()
```

Рис. 6: Инициализация словаря

```
dict[2003]
2-element Vector{String}:
 "Groovy"
 "Scala"
```

Рис. 7: Пример работы словаря

DataFrames

```
using DataFrames
# Задаём переменную со структурой DataFrame:
df = DataFrame(year = P[:,1], language = P[:,2])
73x2 DataFrame
Row year language
     Int64 String31
   1 1951 Regional Assembly Language
   2 1952 Autocode
   3 1954 IPL
   4 1955 FLOW-MATIC
   5 1957 FORTRAN
   6 1957 COMTRAN
   7 1958 LISP
   8 1958 ALGOL 58
   9 1959 FACT
  10 1959 COBOL
  11 1959 RPG
  12 1962 APL
  13 1962 Simula
```

RDatasets

```
# Подгружаем пакет RDatasets:
using RDatasets
# Задаём структуру данных в виде набора данных:
iris = dataset("datasets", "iris")
```

150×5 DataFrame

Row	SepalLength	SepalWidth	PetalLength	PetalWidth	Species
	Float64	Float64	Float64	Float64	Cat
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa
11	5.4	3.7	1.5	0.2	setosa
12	4.8	3.4	1.6	0.2	setosa
13	4.8	3.0	1.4	0.1	setosa

Получение основных статических сведений о каждом столбце в наборе данных

Определения типа переменной: typeof(iris)

DataFrame

describe(iris)

5×7 DataFrame

Row	variable	mean	min	median	max	nmissing	eltype	
	Symbol	Union	Any	Union	Any	Int64	DataType	
1	SepalLength	5.84333	4.3	5.8	7.9	0	Float64	
2	SepalWidth	3.05733	2.0	3.0	4.4	0	Float64	
3	PetalLength	3.758	1.0	4.35	6.9	0	Float64	
4	PetalWidth	1.19933	0.1	1.3	2.5	0	Float64	
5	Species		setosa		virginica	0	CategoricalValue{String, UInt8}	

```
# Отсутствующий тип:
a = missing
typeof(a)
```

: Missing


Рис. 11: Использование "отсутствующего" типа

```
# Определение перечня продуктов:
foods = ["apple", "cucumber", "tomato", "banana"]
# Определение калорий:
calories = [missing.47,22,105]
4-element Vector{Union{Missing, Int64}}:
    missing
  47
  22
 105
```

Рис. 12: Пример работы с данными, среди которых есть данные с отсутствующим типом


```
# Загрузка изображения:
X1 = load("julialogo.png")
460×460 Array(RGBA(N0f8).2) with eltype ColorTypes.RGBA(FixedPointNumbers.N0f8)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0.0) ...
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0,0.0,0.0,0.0)
                                  RGBA{N0f8}(0.0,0.0,0.0,0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0,0.0,0.0,0.0)
RGBA{N0f8}(0.0,0.0,0.0,0.0)
                                  RGBA{N0f8}(0.0,0.0,0.0,0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0,0.0,0.0,0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0.0.
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0,0.0,0.0,0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0,0.0,0.0,0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0.0.
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
 RGBA{N0f8}(0.0.0.0.0.0.0.0.0)
                                  RGBA{N0f8}(0.0.0.0.0.0.0.0)
```

Обработка данных: стандартные алгоритмы машинного обучения в Julia. Кластеризация данных. Метод k-средних




Построение графика без "артефактов"

```
# Фильтрация данных по заданному условию:
filter_houses = houses[houses[!,:sqft].>0,:]
# Построение графика:
x = filter_houses[!,:sqft]
y = filter_houses[!,:price]
scatter(x,y)
```




Кластеризация данных. Метод k ближайших соседей

```
# Все объекты недвижимости:
x = filter_houses[!,:latitude];
y = filter_houses[!,:longitude];
scatter(x,y)
# Соседи:
x = filter_houses[idxs,:latitude];
y = filter_houses[idxs,:longitude];
scatter!(x,y)
```




Обработка данных. Метод главных компонент

```
: y= MultivariateStats.transform(M,F)
# Выделение значений главных компонент в отдельную переменную:
Xr = reconstruct(M, y)
# Построение графика с выделением главных компонент:
scatter(F[1,:],F[2,:])
scatter!(Xr[1,:],Xr[2,:])
```



Обработка данных. Линейная регрессия



```
pv"""
  import numpy
  def find best fit python(xvals,yvals):
     meanx = numpv.mean(xvals)
      meany = numpy.mean(yvals)
      stdx = numpy.std(xvals)
      stdy = numpy.std(yvals)
      r = numpv.corrcoef(xvals,vvals)[0][1]
      a = r*stdy/stdx
      b = meany - a*meanx
      return a,b
  find best fit python = py"find best fit python"
  xpy = PyObject(xvals)
  vpv = Pv0bject(vvals)
 @time a,b = find best fit python(xpy,ypy)
    0.064046 seconds (74.75 k allocations: 5.179 MiB. 91.19% compilation time)
(0.999999961460347, 3.000038831247366)
  import Pkg
  Pkg.add("BenchmarkTools")
  using BenchmarkTools
  @btime a.b = find best fit python(xvals.vvals)
  @btime a,b = find best fit(xvals,vvals)
    2.810 ms (25 allocations: 832 bytes)
    429.597 μs (1 allocation: 32 bytes)
     Resolving package versions...
    No Changes to `~/.julia/environments/v1.10/Project.toml`
    No Changes to `~/.julia/environments/v1.10/Manifest.toml`
```

(0.999999961460344, 3.000038831269194)



Решение задания №1

```
using RDatasets
iris = dataset("datasets", "iris")
```


150 rows x 5 columns

at
tosa.
tosa
tosa
tosa.

Решение задания №1

```
# Построение графика:
plot(size=(500,500),leg=false)

x = iris[!,:SepalLength]
y = iris[!,:PetalLength]
scatter(x, y, markersize=3, title="Распределение признаков SepalLength и PetalLength",
xlabel="SepalLength", ylabel="PetalLength", leg=false)
```



Решение задания №1

```
unique_species = unique(iris[i,:Species])
species figure = plot(legend = false)
for uspecies in unique_species
    iris_sp = iris[iris[i,:Species].==uspecies,:]
    x = iris_sp[i,:SepalLength]
    y = iris_sp[i,:FetalLength]
    scatter!(species_figure, x, y)
end
xlabel!("SepalLength")
ylabel!("PetalLength")
title!('Tris_color-coded by species")
display(species_figure)
```




Рис. 23: Решение задания №1

Решение задания №2-1

```
x1 = x[:,1]
x2 = x[:,2]
x3 = x[:,3]
data = DataFrame(y = y, x1 = X1, x2 = X2, x3 = X3);
lm(@formula(y - x1 + x2 + x3), data)
```

Coefficients:

y - 1 + x1 + x2 + x3


	Coef.	Std. Error	t	Pr(> t)	Lower 95%	Upper 95%
(Intercept)	-0.00140559	0.00310024	-0.45	0.6504	-0.00748934	0.00467815
x1	0.646863	0.00306265	211.21	<1e-99	0.640853	0.652873
x2	0.0425398	0.00328213	12.96	<1e-34	0.0360991	0.0489804
x3	0.558033	0.00308713	180.76	<1e=99	0.551975	0.564091

Решение задания №2-2


```
x = rand(100);
y = 2*x + 0.1 * randn(100);
```

```
a, b = find_best_fit(X, y)
ynew = a * X .+ b

scatter(X, y, title="Fpackux perpeccus", xlabel="X", ylabel="y", color=:blue, leg=false, line=:scatter)
Plots.abline!(a, b, line=:solid)
```




Решение задания №2-2а



Решение задания №2-2b

```
for i in 1:10

IJulia.clear_output(true)
  traj = createPath(100, 1, 10000, 0.3, 0.08)
  if i == 1
      p = plot(traj, title="Трасктория курса акций", xlabel="Длина биномикального дерева в годах",
      ylabel="Курс акций", leg=false)
  end
  p = ploti(traj)
  display(p)
end
```



Решение задания №2-2с

```
using Base.Threads

Threads.@threads for i in 1:10

IJulia.clear_output(true)

traj = createPath(100, 1, 10000, 0.3, 0.08)

if i == 1


g = plot(traj, title="Трасктория курса акций", xlabel="Длина биноминдымого дерева в годых",
 ylabel="Курс акций", leg=false)

end

g = plot!(traj)

display(g)

end
```



Выводы



В ходе выполнения лабораторной работы были изучены специализированные пакеты Julia для обработки данных.